Совет нейросетей

Подробное описание логики работы приложения
для независимого анализа

Назначение: несколько языковых моделей разных разработчиков независимо отвечают на вопрос,
анонимно критикуют друг друга, дорабатывают ответы, голосуют, а председатель пишет итоговое решение.

Стек: Python 3.12+, asyncio, httpx, pydantic, FastAPI, WeasyPrint, python-docx; модели через OpenRouter.
Интерфейсы: командная строка, веб-интерфейс, Telegram-бот.
Исходный код: папка `ai-council/`, ветка `claude/multi-ai-comparison-tool-50nc5z`.
Документ составлен по коду на 10.11.2026.

Содержание

1. Идея и принципы ... 3
2. Архитектура ... 4
3. Участники, роли и настройки ... 6
4. Заседание: этапы по шагам ... 8
   - 4.0 Подготовка: вложения, уточнения, описание картинок ... 8
   - 4.1 Постановка задачи, критерии и обязательные требования ... 8
   - 4.2 Независимые предложения и анонимизация ... 8
   - 4.3 Критика ... 9
   - 4.4 Доработка ... 9
   - 4.5 Голосование ... 9
   - 4.6 Итоговое решение председателя ... 9
5. Режимы заседания и число обращений к моделям ... 11
6. Подсчёт голосов (формулы и пример) ... 13
7. Надёжность: повторы, проверка ответов, кворум, бюджет ... 17
8. Вложения: документы и изображения ... 20
9. Уточняющие вопросы и повтор заседания ... 21
10. Голосовой ввод ... 22
11. Предварительная оценка стоимости ... 23
12. Хранение: архив, стенограмма, отчёты ... 24
13. Интерфейсы: CLI, веб, Telegram ... 25
14. Статистика ... 27
15. Безопасность и развёртывание ... 28
16. Известные ограничения и вопросы для анализа ... 29

Приложение. Карта исходного кода ... 32

1. Идея и принципы

Приложение организует «совет» из нескольких больших языковых моделей (Claude, ChatGPT, Gemini, Kimi, DeepSeek и др.). Вместо одного ответа одной модели пользователь получает решение, прошедшее через независимые предложения, перекрёстную критику, доработку и голосование. Цель — снизить влияние ошибок и «слепых пятен» отдельной модели и получить обоснованный выбор с видимыми альтернативами и рисками.

Ключевые принципы

- **Независимость.** На этапе предложений каждая модель отвечает вслепую — не видя ответов других.
- **Анонимность.** Предложения перемешиваются случайно и получают метки A, B, C… Модели критикуют и голосуют за метки, а не за авторов, чтобы оценивалась идея, а не «бренд» модели.
- **Запрет голоса за себя.** Модель не оценивает и не ранжирует собственный вариант.
- **Измеримость.** Оценки по критериям (1–10) и ранжирование сводятся в формальный подсчёт (нормированный метод Борда).
- **Итог от председателя.** Одна назначенная модель пишет итоговый ответ, опираясь на победителя и на лучшие идеи других вариантов. При расхождении с голосованием председатель обязан объяснить причину.
- **Строгий формат.** Каждый ответ модели — JSON по заданной схеме; ответ проверяется, при ошибке модель просят исправиться.
- **Прозрачность.** Сохраняется полная стенограмма: каждый запрос, сырой ответ, попытки, стоимость, токены.
- **Контроль расходов.** Жёсткий лимит стоимости одного заседания и предварительная оценка цены до запуска.

Что получает пользователь

- Итоговое решение (готовый к использованию ответ в формате Markdown), обоснование выбора, особые мнения, риски.
- Таблицу голосования, все предложения (исходные и доработанные), отзывы критиков, бюллетени; согласие совета, пометки бюллетеней и (по желанию) проверку фактов лидеров.
- Отчёты в PDF, Word и Markdown — полный, итог (решение с обоснованием) или только решение совета.
- Расходы по каждой модели, длительность, сведения о сбоях.

2. Архитектура

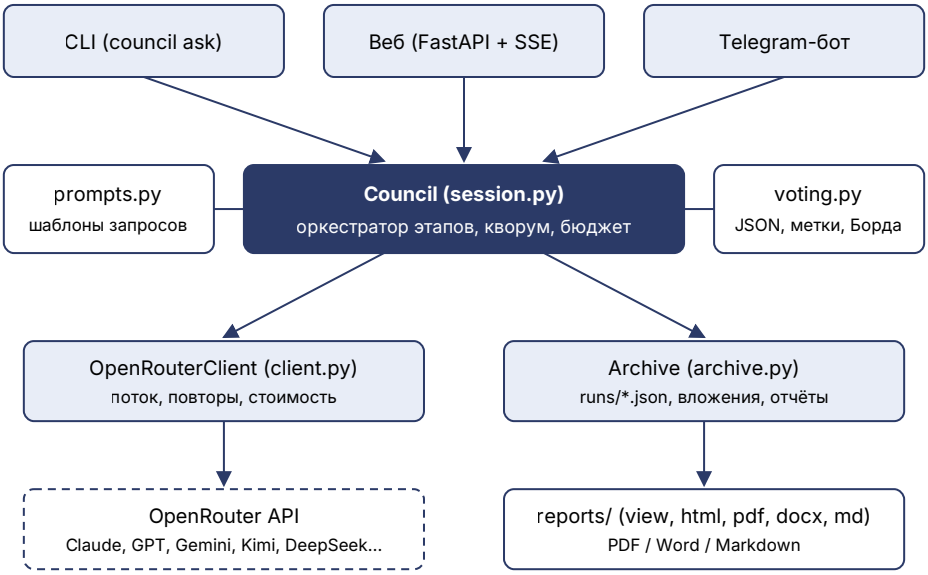


Рис. 1. Основные компоненты и направления вызовов

Слои

Слой	Ответственность
Интерфейсы (`cli.py`, `web/app.py`, `telegram/bot.py`)	Приём вопроса и настроек, загрузка вложений, показ хода заседания в реальном времени, выдача результата и отчётов, архив.
Оркестратор (`session.py`, класс `Council`)	Последовательность этапов, параллельные вызовы, анонимизация, проверка ответов, кворум, бюджет, стенограмма, события прогресса.
Промпты (`prompts.py`)	Тексты запросов к моделям на каждом этапе (на английском — модели точнее следуют инструкциям; ответы — на языке из настроек).
Схемы (`schemas.py`)	Строгие pydantic-модели ответов: Framing, Proposal, Revision, CritiqueSet, Ballot, Verdict, ImageNotes.
Голосование (`voting.py`)	Извлечение JSON из ответа, нормализация меток и оценок, назначение анонимных меток, подсчёт итогов.
Клиент (`client.py`)	HTTP-запросы к OpenRouter с потоковой передачей, сетевые повторы, учёт стоимости, обработка пустых и обрезанных ответов.
Хранилище (`archive.py`, `report.py`)	Сохранение стенограммы, файлов-вложений и отчётов; поиск; пересборка отчётов; цепочки уточнений.
Отчёты (`reports/`)	Единое представление заседания (`View`) и генерация HTML/PDF, DOCX, Markdown; фирменное оформление.
Вспомогательное	`attachments.py` (файлы), `transcribe.py` (голос), `estimate.py` (цена, модели, зрение), `stats.py` (статистика), `mock.py` (демо-режим без затрат), `config.py` (настройки).

Поток данных одного заседания

1. Интерфейс собирает вопрос, режим, участников, роли, бюджет, вложения и (если это уточнение) ссылку на предыдущее заседание.
2. Строится конфигурация: базовый `config.yaml` + пользовательские переопределения (`with_overrides`), с проверкой корректности.
3. Загружается каталог моделей OpenRouter (кэш 10 минут) — для проверки, какие модели «видят» картинки.
4. Создаётся `Council` с клиентом (реальным или демо) и обработчиком событий; вызывается `run()`.
5. Каждый этап порождает события (`stage`, `call`, `member_done`, `member_failed`, `cost`, `tally`, `verdict`…), которые интерфейс показывает пользователю.
6. Результат (`SessionResult`) сохраняется в архив как JSON, вложения — в отдельную папку, затем строятся отчёты.

3. Участники, роли и настройки

Состав совета по умолчанию

Имя	Модель (OpenRouter)	Включена	Роль
claude	`anthropic/claude-sonnet-4.5`	да	председатель
chatgpt	`openai/gpt-5`	да	—
gemini	`google/gemini-2.5-pro`	да	—
kimi	`moonshotai/kimi-k2`	да	—
deepseek	`deepseek/deepseek-chat`	да	адвокат дьявола
grok, qwen, mistral, llama, perplexity	`x-ai/grok-4`, `qwen/qwen3-max`, `mistralai/mistral-large`, `meta-llama/llama-4-maverick`, `perplexity/sonar-pro`	нет	резерв

Роли

- **Участник.** Предлагает вариант, критикует чужие, дорабатывает свой, голосует.
- **Председатель** (`chair`). Дополнительно формулирует уточнённый вопрос и критерии (этап 0) и пишет итоговое решение (этап 6). По умолчанию (`chair_proposes: false`) **своего варианта не предлагает** и не дорабатывает, но критикует и голосует, оценивая все варианты, — так он не судит собственный вариант. Если без него участников меньше кворума, он предлагает вариант как обычный участник. Настройка `chair_proposes: true` (галочка в вебе, `--chair-proposes`) возвращает прежнюю схему с инструкцией быть нейтральным «включая свой вариант».
- **Общее начало запросов («шапка»).** На этапах 1–6 каждый запрос начинается одинаково: уточнённый вопрос, исходный запрос пользователя дословно и **обязательные требования** R1, R2, … (раздел 4.1); перед шапкой — вложения. Правило формата: если запрос задаёт структуру, разделы, таблицу или иной формат — следовать ему точно (в режиме «компактные варианты» — только председателю).
- **Адвокат дьявола** (`devil_advocate`, необязательно). На этапах предложений, критики и доработки получает дополнительную инструкцию искать неочевидные альтернативы, скрытые допущения и слабые места, оставаясь конструктивным.

Системная инструкция (общая для всех)

Каждая модель получает роль «члена экспертного совета из моделей разных лабораторий» и правила: думать независимо, не соглашаться только потому, что согласны другие; быть конкретной; критиковать честно, без лести; оценивать идеи, а не авторов; инструментов и файлов нет — всё содержимое прямо в ответе; писать на заданном языке; отвечать **ровно одним JSON-объектом**. Для каждой модели системная инструкция (вместе с её ролью) одинакова на всех этапах — это нужно для кэширования у провайдера.

Основные настройки (`config.yaml`)

Параметр	По умолчанию	Смысл
`mode`	debate	quick / debate / evaluate (см. раздел 5)
`debate_rounds`	1	число раундов «критика → доработка» (0–5)
`min_quorum`	2	минимум полученных предложений, иначе заседание прерывается
`max_cost_usd`	2.0	жёсткий лимит стоимости одного заседания
`temperature`	0.7	температура генерации (можно задать для каждого участника)
`max_tokens` / `max_tokens_cap`	8000 / 32000	лимит ответа (длинные ответы продолжаются с места остановки) и потолок для повторов
`chair_proposes` / `chair_follows_vote`	false / true	председатель без своего варианта; председатель следует голосованию
`compact_proposals` / `compact_words`	false / 700	компактные варианты (раздел 5) и их длина в словах
`fact_check`	выключена	проверка фактов лидеров моделью с поиском (раздел 6)
`reasoning_effort`	low	глубина скрытых рассуждений «думающих» моделей: none/low/medium/high
`timeout_s`	180	таймаут ожидания; весь поток ответа ограничен ×3 (540 с)
`max_retries`	3	повторы при сетевых ошибках, 429, 5xx, пустом ответе
`json_retries`	2	повторы, если ответ не соответствует схеме
`max_concurrency`	8	максимум одновременных запросов к моделям
`language`	Russian	язык ответов
`transcribe_model`	google/ gemini-2.5-flash	модель расшифровки голосовых сообщений
`branding`	пусто	название, логотип, цвет и колонтитул отчётов

Все настройки меняются и на странице «Настройки» веб-интерфейса. При загрузке проверяется: имена участников уникальны; председатель и адвокат дьявола входят во включённых участников; число включённых не меньше кворума. Пользователь в вебе и Telegram может переопределить состав, председателя, адвоката и бюджет для одного заседания — результат проверяется по тем же правилам; если председатель выключен, им становится первый включённый.

4. Заседание: этапы по шагам



Рис. 2. Последовательность этапов (голубые — все участники параллельно)

4.0 Подготовка: вложения, уточнения, описание картинок

- Если вопрос — уточнение к прошлому заседанию, в оркестратор передаётся история (до 4 предыдущих пар «вопрос — решение»), а вложения исходного заседания объединяются с новыми (без дублей). Подробнее — раздел 9.
- Если есть изображения, а среди участников есть модели без поддержки картинок, одна «зрячая» модель (предпочтительно председатель) заранее описывает каждое изображение текстом: весь видимый текст дословно, числа, содержимое таблиц, оси и значения графиков, элементы схем. Это отдельный вызов (этап `describe`). Описание затем получают «незрячие» модели вместо самих картинок. Если ни одна модель не видит картинки — пользователь получает предупреждение, изображения пропускаются. Подробнее — раздел 8.

4.1 Постановка задачи, критерии и обязательные требования (этап 0)

Если пользователь сам не задал критерии, председатель: (1) переформулирует вопрос точно и нейтрально, не отвечая на него; (2) предлагает 3–5 коротких критериев оценки; (3) выписывает **обязательные требования** — то, что пользователь потребовал явно: структура, разделы, таблицы, длина, язык, ограничения, что обязательно включить или исключить. Требования переписываются точно, без смягчения и выдумывания (до 10). Это не критерии: их нарушение не компенсируется высокими оценками за другое. Схема ответа: `{"refined_question", "criteria", "requirements"}`.

Если председатель не ответил — исходная формулировка и критерии «Эффективность», «Реалистичность», «Риски». Требования попадают в шапку всех следующих запросов и в отчёт.

4.2 Независимые предложения и анонимизация (этапы 1–2)

Участники (кроме председателя без варианта) параллельно получают шапку, контекст, критерии и вложения и предлагают **свой лучший вариант**, не видя чужих:

```
{"title": "краткое название", "summary": "сам вариант (Markdown)",
 "reasoning": "почему это лучший выбор", "pros": [...], "risks": [...], "confidence": 0.0–
1.0}
```

В обычном режиме `summary` — полный ответ в запрошенном формате; в режиме **«компактные варианты»** — суть сжато (до `compact_words` слов) без оформления: формат применит председатель. Уверенность в подсчёте не используется. Меньше `min_quorum` предложений — заседание прерывается.

Анонимизация: авторы случайно перемешиваются и получают метки A, B, C…; соответствие знает только программа. **Порядок показа:** на критике и голосовании каждый судья видит варианты в своём случайном порядке — так гасится эффект позиции (первые показанные обычно оценивают выше). В режиме «Оценка вариантов» этап 1 пропускается: варианты задаёт пользователь (2–26).

4.3 Критика (этап 3)

Каждый участник оценивает все варианты, **кроме своего**: оценка 1–10 по каждому критерию, сильные и слабые стороны.

```
{"reviews": [{"label": "A", "scores": {"Критерий 1": 7, ...},
              "strengths": [...], "weaknesses": [...]}, ...]}
```

Шкала одна для всех критериев: **1–2** — неверно или непригодно; **3–4** — серьёзные недостатки; **5–6** — приемлемо, с заметными слабостями; **7–8** — хорошо, мелкие замечания; **9–10** — отлично (редко). Оценивать суть, а не длину и стиль; невыполненное требование — слабость. Каждое нарушение обязательного требования указывается как «VIOLATES Rn: …». В компактном режиме критикам сказано не снижать оценку за отсутствие оформления.

Проверка ответа: оценены все ожидаемые варианты и только они, по всем критериям, в диапазоне 1–10; ответ непривычной формы (оценки «7/10», отзывы по меткам) приводится к нужной.

4.4 Доработка (этап 4, только режим «Дебаты»)

Каждый автор получает: свой вариант; **анонимные** отзывы на него; **чужие варианты целиком**. По шагам: честно сравнить свой вариант с чужими; исправить слабости, сохранить сильное, взять конкретные идеи у других (с меткой); перечислить критику, которую **не принял**, и почему; менять основной подход только из-за конкретного довода. В ответе: `comparison`, `borrowed`, `not_accepted`, `position` (сохранена / доработана / подход сменён), `changes`. Итог по позициям — рядом с голосованием; если подход сменили половина и больше — пометка «варианты могли сблизиться». Исходные версии сохраняются для отчёта.

4.5 Голосование (этап 5)

Каждый участник получает шапку (с исходным запросом и требованиями), финальные версии всех вариантов, кроме своего (документы — если вместе не больше 20 000 символов), и ранжирует их: `{"ranking": ["B", "D", "A"], "rationale": "..."}`. Вариант, нарушающий обязательное требование, ставится ниже всех соблюдающих. Подсчёт и сигналы надёжности — раздел 6.

4.6 Итоговое решение председателя (этап 6)

Председатель получает: шапку; финальные варианты вместе с «что изменено после критики» и «что автор не принял»; таблицу голосования; согласие совета; решающие голоса и бюллетени против общего мнения; ничью за первое место (если есть); проверку фактов (если была); сводку критики — с пометкой, что она относится к версиям **до** доработки.

```
{"winner": "A", "final_answer": "полный ответ (Markdown)", "why": "...",
 "dissent": [...], "risks": [...], "deviation": ""}
```

- **Следовать голосованию** (`chair_follows_vote: true`): победитель — лидер подсчёта; при ничьей за первое место — любой из лидеров без особой причины. Другой вариант — только по причине в `deviation`: fact (проверка фактов опровергла ключевое у лидера), risk (серьёзный риск, который **остался** в финальном тексте лидера, с цитатой), process (лидер не отвечает на вопрос или нарушает требования). Без причины ответ возвращается председателю. Отступление выделяется над решением и учитывается в статистике.
- **Итоговый ответ** — синтез победителя и лучших идей других, в запрошенном формате, с проверкой каждого обязательного требования; в компактном режиме председатель разворачивает сжатые варианты в полный ответ.
- **Новые факты**, которых нет ни в вариантах, ни в проверке фактов, не добавлять; если необходимо — пометить «(добавлено председателем)». Числа голосования копировать точно. При низком согласии — сказать, в чём разделился совет.

Запасной путь: председатель не ответил — победитель = лидер голосования, итог — его текст без синтеза, с пометкой.

5. Режимы заседания и число обращений к моделям

Режим	Предложения	Критика	Доработка	Назначение
Быстрый (quick)	модели	нет	нет	Дешёвый ответ: предложения → голосование → итог. Средняя оценка критики в таблице отсутствует.
Дебаты (debate)	модели	N раундов	N раундов	Основной режим: полный цикл с доработкой (по умолчанию N = 1).
Оценка вариантов (evaluate)	пользователь	1 раунд	нет	Сравнение готовых вариантов пользователя (2–26). Каждая модель оценивает и ранжирует все варианты. Включается автоматически, если переданы варианты.

Число вызовов моделей

Обозначим M — число участников, N — число раундов. Без учёта повторов:

Этап	Быстрый	Дебаты	Оценка
Описание картинок (если нужно)	1	1	1
Постановка (если критерии не заданы)	1	1	1
Предложения	M − 1	M − 1	0
Критика	0	M·N	M
Доработка	0	(M − 1)·N	0
Голосование	M	M	M
Итог	1	1	1
Итого при M = 5, N = 1	**11**	**20**	**12**

Председатель по умолчанию без своего варианта (M − 1 авторов). Если он тоже предлагает вариант — 12 / 22 / 12.

Внутри этапа запросы идут параллельно (не более `max_concurrency` одновременно), этапы — строго последовательно, потому что каждый следующий зависит от результатов предыдущего. Поэтому длительность заседания определяется самой медленной моделью на каждом этапе.

Экономия: компактные варианты и кэширование

Компактные варианты (по выбору: настройка по умолчанию, галочка в форме, «📝 Компактно» в Telegram, `--compact`): участники пишут суть сжато, полный ответ в нужном формате пишет только председатель. Каждая модель читает все чужие варианты, поэтому цена падает примерно в 2–3 раза; риск — часть деталей может не дойти до итога. **Кэширование:** одинаковая системная инструкция и общее начало запросов (вложения, история, шапка) кэшируются у провайдера — повторное чтение на 50–90%

дешевле (OpenAI, DeepSeek, Grok — автоматически; Claude и Gemini — по метке, которую ставит программа). В отчёте видно, сколько входных токенов прочитано из кэша.

6. Подсчёт голосов (формулы и пример)

Нормированный балл Борда

Каждый бюллетень — ранжирование n вариантов (без собственного). Позиция i (с нуля) даёт варианту

```
points = (n − 1 − i) / (n − 1)      — первое место = 1, последнее = 0;
                                      если в бюллетене один вариант, он получает 1.
borda(вариант) = среднее points по всем бюллетеням, где он встречается   (0..1)
```

Нормировка нужна потому, что бюллетени разной длины: участник не голосует за себя, а в режиме «Оценка» авторов нет — без нормировки варианты, получившие больше бюллетеней, имели бы преимущество.

Средняя оценка критики

```
avg_score(вариант) = среднее по рецензентам от (среднее оценок рецензента по всем
критериям)   (1..10)
```

Критерии равновесны. Используются отзывы последнего раунда критики. Оценка показывается в отчёте, но в порядке вариантов не участвует: в «Дебатах» она относится к версиям до доработки.

Метод Шульце — основной порядок

```
d[X,Y] — в скольких бюллетенях X выше Y (где есть оба)
прямая победа X над Y: сила d[X,Y], если d[X,Y] > d[Y,X], иначе 0
p[X,Y] — сильнейший путь из X в Y (сила пути = самое слабое звено)
X выше Y, если p[X,Y] > p[Y,X];   Шульце(X) = скольких соперников X побеждает
```

Метод выбирает победителя Кондорсе (кто выигрывает у каждого один на один), устойчив к похожим вариантам-«клонам» и к стратегическому «утоплению» соперника. Пример, где Борда ошибается: 3 бюллетеня A>B>C и 2 бюллетеня B>C>A — по Борда лидер B (0,70 против 0,60), но A выигрывает у B и C со счётом 3:2, и Шульце ставит первым A.

Попарное сравнение (метод Копленда)

```
для каждой пары X, Y — только бюллетени, где есть оба:
  X выше Y в большинстве → X: +1, Y: −1;   поровну → 0
pairwise(вариант) = побед − поражений
```

Порядок и разрешение ничьих

1. по Шульце — сколько соперников вариант побеждает;
2. при равенстве — по баллу Борда;
3. при равенстве — по попарному счёту;
4. при равенстве — жребий (метки вариантов случайны).

Средняя оценка критики в порядке не участвует: она дана версиям до доработки, а голосование — финальным.

Если ничья по Борда была, в таблице указано, чем она решена. Пример: бюллетени A>B>D, B>D>A, B>D>A дают A и D одинаковые 0,33 по Борда, но D выше A в двух бюллетенях из трёх — D ставится выше, хотя у A есть первое место.

Согласие совета

```
для каждой пары бюллетеней на общих вариантах (≥ 2):
  τ = (согласных пар − несогласных пар) / все пары     (−1..1)
согласие = среднее τ;   ≥ 0,6 высокое · 0,3–0,6 среднее · < 0,3 низкое
```

Высокое согласие означает, что модели одинаково упорядочили варианты, — это согласие, а не гарантия правоты.

Классический W Кендалла не подходит: в каждом бюллетене нет своего варианта. Согласие показывается в итогах, отчётах и Telegram; при низком — предупреждение над решением. На выбор победителя оно не влияет.

Ничья за первое место

Если первые варианты равны по Шульце, Борда и попарному счёту, это не победа, а ничья: над решением «🤝 Ничья за первое место: A, D — по голосам их не различить». Председатель выбирает любого из лидеров без особой причины, и это не считается отступлением от голосования.

Покрытие пар и решающие голоса

Показывается, сколько раз сравнивалась каждая пара вариантов (в скольких бюллетенях есть обе); при одном сравнении — «мало данных», при менее чем трёх вариантах — предупреждение, что выбор по сути делает председатель. Для каждого бюллетеня проверяется, сменился бы лидер без него: «без бюллетеня deepseek лидером был бы A» — так видно, от каких голосов зависит победа, даже если бюллетень не помечен как «против общего мнения».

Проверка бюллетеней (защита от стратегического голосования)

Каждый бюллетень из 3+ вариантов сравнивается с общим порядком **остальных** бюллетеней. Пометки: «против общего мнения» (τ с общим порядком < 0) и «лидер последним» (вариант, который остальные ставят первым, у голосующего на последнем месте). Голоса не отбрасываются — расхождение бывает честным, — но подсчёт повторяется без помеченных бюллетеней: если лидер меняется, пользователь и председатель видят, что «победа зависит от спорных голосов».

Проверка фактов (необязательно)

Если включена (`fact_check.enabled`, галочка в вебе, кнопка в Telegram, `--fact-check`), после голосования модель с поиском в интернете (по умолчанию `perplexity/sonar-pro`) проверяет до 5 ключевых фактических утверждений в каждом из двух лидеров: подтверждено / опровергнуто / не удалось проверить / из документов пользователя, с пояснением и ссылками. Председатель обязан не повторять опровергнутое и подавать

непроверенное как неуверенное. Стоимость — 2 запроса с поиском; сбой проверки не останавливает заседание.

Контроль председателя

В статистике для каждого председателя показано, в скольких заседаниях он назвал победителем не лидера голосования, и среднее согласие совета. Изредка и с обоснованием — нормально; часто — повод сменить модель председателя.

Также считается число первых мест (информационно, на порядок не влияет). Лидер таблицы передаётся председателю как ориентир; окончательный победитель — тот, кого выбрал председатель (обычно совпадает).

Пример (4 участника)

Авторы: A — gemini, B — claude, C — deepseek, D — chatgpt. Каждый ранжирует три чужих варианта (n = 3, баллы 1 / 0,5 / 0):

Голосует	1-е	2-е	3-е
gemini (A)	B	D	C
claude (B)	D	A	C
deepseek (C)	B	A	D
chatgpt (D)	B	A	C

Вариант	Баллы	Борда	Первых мест
B	1, 1, 1	1,00	3/3
A	0,5, 0,5, 0,5	0,50	0/3
D	0,5, 1, 0	0,50	1/3
C	0, 0, 0	0,00	0/3

A и D равны по Борда — их порядок решит средняя оценка критики. Председателю передаётся текст вида `1. B: borda=1.00, critique=8.1, first places=3/3`.

7. Надёжность: повторы, проверка ответов, кворум, бюджет

Каждое обращение к модели проходит два уровня защиты: сетевой (в клиенте) и смысловой (в оркестраторе).

Уровень 1. Клиент OpenRouter

- Запрос с потоковой передачей (SSE). Это позволяет видеть, что модель жива: «думает» (идут скрытые рассуждения или служебные строки сервера) или «пишет» (идёт текст ответа).
- В запросе передаются `usage.include` (OpenRouter возвращает фактическую стоимость) и `reasoning.effort` (глубина рассуждений для «думающих» моделей).
- **Временные ошибки** (HTTP 408, 409, 425, 429, 500, 502, 503, 504, сетевые сбои, не-JSON ответ, пустой список вариантов, поток дольше 3×таймаута) → повтор с экспоненциальной задержкой `min(2^попытка, 30) + случайная доля` секунд, до `max_retries + 1` попыток.
- **Постоянные ошибки** (прочие 4xx, ошибка провайдера) → немедленный отказ.
- **Пустой ответ из-за рассуждений** (`finish_reason = length`, текста нет): модели ставится явный бюджет на рассуждения — половина лимита, затем 2048 токенов; если и это не помогло — понятная ошибка с советом снизить глубину рассуждений. Лимит не раздувается: раньше «думающая» модель могла сжечь 32 000 токенов впустую.
- **HTTP 402 «in_flight_budget_exhausted»** (OpenRouter временно не принимает новые запросы, пока выполняются уже отправленные): ожидание (по `Retry-After`, до 90 с) и повтор до 6 раз; после первого такого отказа запросы идут не более чем по 2 одновременно. Настоящая нехватка средств — сразу понятная ошибка.
- Стоимость и токены **всех** попыток суммируются, включая неудачные; при отказе потраченное передаётся вверх и учитывается.

Уровень 2. Оркестратор (`_ask`)

- Ответ разбирается терпимо (`extract_json`): снимается обёртка ```` ```json ````, отбрасывается текст до и после, допускаются переводы строк внутри строк и лишняя запятая перед `}`/`]`; берётся первый JSON-объект.
- Если в ответе несколько частей (после продолжения), разбирается сначала склейка, затем последняя часть отдельно.
- Объект проверяется по схеме pydantic и дополнительными правилами этапа (метки, критерии, диапазоны, полнота).
- Если ответ **упёрся в лимит длины** — модель просят продолжить ровно с места остановки, части склеиваются (до 4 продолжений). Если не помогло — просят написать компактнее, сохранив все разделы.
- Ответ **непривычной формы** приводится к нужной: раздел объектом или списком вместо текста превращается в текст с заголовками, поля с другими названиями и лишние обёртки распознаются, оценки «7/10» и проценты понимаются.

- Если ответ **не по формату** — в диалог добавляются сам ответ и сообщение «ваш ответ не принят: <ошибка>, ответьте ещё раз одним корректным JSON» (модель видит свою ошибку).
- Всего до `json_retries + 1` попыток (по умолчанию 3). Каждая попытка записывается в стенограмму с сырым ответом и ошибкой; ошибки проверки показываются человеческим языком («нет поля „ranking“», а не трассировка pydantic).

Ответ «в файле» вместо содержимого

Некоторые модели пишут «исследование сохранено в файл, [скачать](sandbox:/mnt/data/...)», хотя через API файлов не создают, и содержимое теряется. Всем моделям сказано, что инструментов и файлов нет и всё содержимое должно быть в самом ответе. Ответы на этапах предложений, доработки и итога проверяются на такие ссылки (песочница, локальные пути, ссылки на файлы вместо сайтов, фразы «сохранил/прилагаю файл», «скачайте отчёт»). Если ссылка найдена, модели возвращают ответ с просьбой вставить всё содержимое. Если и после повторов ссылка осталась, ответ принимается с пометкой в сбоях, а критики оценивают такой вариант как неполный.

Выбывание участников и кворум

- На параллельных этапах отказ одного участника не останавливает заседание: он выбывает из этого этапа, сбой записывается в статистику и показывается пользователю.
- Выбывший на этапе предложений не имеет своего варианта, но может участвовать в критике и голосовании.
- Кворум проверяется только после этапа предложений: получено меньше `min_quorum` → заседание прерывается.
- Отказ председателя на этапе 0 → критерии по умолчанию; на этапе 6 → итог по голосованию (раздел 4.6).

Бюджет

Перед **каждым** запросом сравнивается накопленная стоимость с `max_cost_usd`. При достижении лимита заседание прерывается полностью (исключение «лимит бюджета» не гасится на параллельных этапах). Так как запросы одного этапа уходят параллельно, фактическая стоимость может превысить лимит на стоимость запросов, уже отправленных в этот момент.

Журналы для диагностики

Для каждого заседания сохраняются события с временем (`…events.jsonl`), сбойные заседания — отдельно (`runs/failed`), у программы есть журнал `runs/logs`. Всё это собирается в один zip без ключей (в вебе — «Диагностика», в Telegram — `/logs`).

Отмена

Пользователь может остановить заседание в любом интерфейсе; задача отменяется, незавершённое заседание в архив не сохраняется (в вебе оно видно в списке как «остановлено» до перезапуска сервера).

События прогресса

Для каждого обращения генерируются фазы: в очереди → отправлено → думает → пишет → проверяю → готово / повтор / сбой, с прошедшим временем, числом символов, номером попытки и причиной повтора. Частые обновления «думает/пишет» прореживаются (не чаще раза в 0,8 с на участника), смена фазы отправляется сразу. Веб-страница дополнительно получает «сердцебиение» раз в 10 с.

8. Вложения: документы и изображения

Поддерживаемые файлы и лимиты

Тип	Обработка
Изображения: JPG, PNG, WEBP, GIF, BMP	Поворот по EXIF, уменьшение до 1600 px по длинной стороне, передача моделям как картинки.
PDF	Извлечение текста по страницам (pypdf).
Word (.docx)	Текст абзацев и таблиц.
Excel (.xlsx, .xlsm)	Листы как таблицы (до 2000 строк на лист).
Текстовые: TXT, MD, CSV, TSV, JSON, XML, YAML, HTML, код	Как текст; CSV/TSV — как таблица (до 3000 строк).

Лимиты: до 10 файлов, до 20 МБ на файл, до 60 000 символов текста на документ, до 150 000 символов на все документы запроса (лишнее обрезается с предупреждением).

Как вложения попадают к моделям

- Текст документов, примечание о картинках и (для уточнений) история добавляются **перед** текстом запроса на этапах: постановка, предложения, критика, доработка, итог. На этапе голосования вложения не передаются (экономия; модели уже знакомы с материалами).
- Модели, поддерживающие изображения, получают сами картинки. Поддержка определяется по каталогу OpenRouter (`input_modalities`); если каталог недоступен — по списку известных «незрячих» моделей (deepseek, kimi-k2, qwen3-max, mistral-large); если неизвестно — считается, что модель видит.
- «Незрячие» модели получают текстовые описания картинок, подготовленные на этапе 4.0.
- Файлы сохраняются в архиве вместе с заседанием; в отчётах выводится их список, картинки — миниатюрами.

9. Уточняющие вопросы и повтор заседания

Уточнение («Задать уточнение» / «Уточнить» / `--followup`)

1. Пользователь выбирает прошлое заседание и задаёт новый вопрос.
2. Из архива берётся цепочка: история самого прошлого заседания (если оно тоже было уточнением) плюс его пара «вопрос — итоговое решение» (решение обрезается до 4000 символов). Хранятся последние 4 звена.
3. Вложения прошлого заседания загружаются из архива и объединяются с новыми (дубли по имени и размеру отбрасываются, всего ≤ 10).
4. Новое заседание проходит **полный цикл**, но в начало запросов (этапы 0, 1, 3, 4, 6) добавляется блок: «Это УТОЧНЯЮЩИЙ вопрос. Ранее совет обсуждал тему (от старых к новым). Опирайтесь на эти выводы; пересматривайте их, если новый вопрос этого требует» и список прошлых вопросов и решений.
5. В результате сохраняются ссылка на родителя (`followup_of`) и цепочка (`thread`); в интерфейсе и отчётах показывается «↳ Уточнение к заседанию …».

Совет при уточнении видит только итоговые решения прошлых заседаний, а не их предложения, критику и голосование.

Повтор заседания

При каждом запуске сохраняются исходные настройки (`request`): вопрос, режим, раунды, критерии, варианты, контекст, участники, председатель, адвокат дьявола, бюджет. «Повторить» заполняет форму этими значениями и копирует вложения; пользователь может всё изменить перед запуском. Для старых заседаний без `request` настройки восстанавливаются из стенограммы. Повтор — это новое независимое заседание; результаты моделей могут отличаться (температура 0,7, случайные метки).

10. Голосовой ввод

- **Веб:** кнопка микрофона записывает звук в браузере (MediaRecorder; требуется HTTPS) и отправляет на сервер; расшифровка добавляется в поле вопроса — пользователь может её отредактировать.
- **Telegram:** голосовые, аудиофайлы и видеосообщения скачиваются, расшифровываются, бот показывает «🎤 Распознано: …» и открывает карточку нового вопроса (как для текста).
- **Обработка:** звук любого формата (OGG/Opus, WebM, MP4/M4A, MP3, WAV) декодируется библиотекой PyAV в WAV 16 кГц моно; максимальная длина — 5 минут. WAV отправляется модели `transcribe_model` через OpenRouter как аудио-вход с инструкцией дословно расшифровать речь. Стоимость расшифровки небольшая и учитывается отдельно от заседания.

11. Предварительная оценка стоимости

До запуска (CLI, веб, карточка в Telegram) показывается диапазон стоимости. Алгоритм (`estimate.py`):

1. Строится план вызовов каждого участника по режиму и раундам (раздел 5), с учётом числа вариантов, которые он читает.
2. Вход каждого запроса = инструкции этапа + **вопрос** (уточнённый и исходный, ≈ символы / 3 × 1,3) + вложения + то, что модель читает на этапе: на критике, доработке, голосовании и итоге — **все чужие варианты целиком**. Поэтому главное, от чего зависит цена, — длина вариантов, умноженная на число участников.
3. Длина ответов на каждом этапе берётся **из ваших прошлых заседаний**: по стенограммам считается, сколько выходных токенов модели реально тратят на один принятый ответ — вместе с продолжениями длинных ответов, повторами и скрытыми рассуждениями (медиана по последним 30 заседаниям). Без истории — по умолчанию: вариант ≈ 2 500 токенов, после доработки ≈ 3 000, итог ≈ 4 000, критика ≈ 350 на вариант.
4. Вложения: токены документов (символы / 3), ~1100 токенов на картинку для «зрячих» или ~350 токенов описания для «незрячих»; небольшие документы — и на голосовании.
5. Токены умножаются на цены моделей из каталога OpenRouter (у моделей с поиском — плюс плата за запрос). Нижняя граница — сумма; верхняя — ×1,6, если длины взяты из истории (от 3 заседаний), иначе ×2,5.
6. Рядом показывается, сколько **фактически** стоили последние похожие заседания (тот же режим, ±1 участник), и баланс OpenRouter.

Также проверяется, что все модели из настроек существуют в OpenRouter; для неизвестных предлагаются похожие названия.

12. Хранение: архив, стенограмма, отчёты

Файлы в папке `runs/`

Файл	Содержимое
`<id>.json`	Источник правды: полная стенограмма (см. ниже). id = дата-время + краткое название вопроса.
`<id>.pdf / .docx / .md`	Полный отчёт.
`<id>.summary.pdf / .docx / .md`	Итог: решение, почему, особые мнения, риски.
`<id>.decision.pdf / .docx / .md`	Только решение совета: вопрос и итоговый ответ.
`<id>.files/`	Исходные файлы вложений.
`.reports-version`	Версия формата отчётов; при её изменении после обновления все отчёты пересобираются в фоне.

Содержимое стенограммы

Вопрос и уточнённый вопрос; критерии; режим; соответствие меток авторам; исходные и финальные предложения; отзывы последнего раунда критики; бюллетени; таблица голосования; итоговое решение; статистика по участникам (вызовы, токены, стоимость, сбои); общая стоимость; время начала и длительность; описания вложений и картинок; ссылка на родителя и цепочка уточнений; исходные настройки запуска; **журнал всех обращений** (этап, участник, фактическая модель, номер попытки, сырой ответ, разобранный объект или ошибка, стоимость, токены).

Отчёты

- Все форматы строятся из одного представления (`View`), поэтому их можно пересобрать в любой момент, в том числе для старых заседаний.
- Полный отчёт: заголовок (короткое название), исходный вопрос с сохранением форматирования, вложения, итоговое решение, таблица голосования, все предложения с авторами, критика, бюллетени, расходы, сбои.
- PDF: оглавление с номерами страниц и закладки; широкие таблицы ужимаются по ширине страницы. Word: поле оглавления (обновляется при открытии). Markdown: текстовая версия.
- Фирменное оформление: название, логотип, цвет и текст колонтитула из настроек.
- Безопасность генерации: в Markdown модели отключён «сырой» HTML; генератор PDF не загружает внешние ресурсы (только встроенные data-URL).

13. Интерфейсы: CLI, веб, Telegram

Командная строка (`python -m council`)

Команда	Назначение
`ask "вопрос"`	Заседание. Ключи: режим, раунды, критерии, варианты (`--option`, `--options-file`), `--compact`, контекст, вложения, `--followup`, `--mock` (демо без затрат), оценка стоимости с подтверждением. Живая строка прогресса с таймерами.
`models [поиск]`	Поиск моделей в каталоге OpenRouter (новые сверху; варианты `:batch` и `:free` скрыты); `models --upgrades` — более новые версии моделей совета.
`archive`, `reports`	Список заседаний; (пере)сборка отчётов.
`stats`	Статистика.
`web`, `telegram`	Запуск веб-сервера или бота.

Веб-интерфейс

- Одностраничное приложение (без фреймворков). Форма: вопрос, режим, раунды, участники, роли, бюджет, критерии, варианты, вложения, голосовой ввод; предварительная оценка стоимости.
- Заседание запускается как фоновая задача сервера; ход передаётся через Server-Sent Events с возможностью переподключения без потери событий (`Last-Event-ID`) — можно закрыть вкладку и вернуться.
- Живые карточки участников по этапам, полноэкранный просмотр любого ответа, итог, таблица голосования, отчёты, архив с поиском и фильтром, «Уточнить», «Повторить», статистика, уведомление об окончании.
- В верхней панели — остаток на балансе OpenRouter (обновляется раз в 2 минуты и после заседания; цвет — сколько осталось; нажатие открывает пополнение). Галочки формы: «Компактные варианты», «Проверка фактов».
- **Страница «Настройки»**: участники и модели (с подсказкой о более новых версиях), параметры заседания и экономии, проверка фактов, оформление, а также версия программы, обновление и перезапуск из браузера (через службу на сервере); перед каждым сохранением делается резервная копия `config.yaml`.
- Основные адреса API: `POST /api/sessions`, `GET /api/sessions/{id}/events`, `POST …/cancel`, `GET …/report`, `POST …/repeat`, `POST /api/estimate`, `POST /api/uploads`, `POST /api/transcribe`, `GET /api/stats`, `GET /api/balance`, `GET /api/diagnostics`.

Telegram-бот

- Доступ только для пользователей из `TELEGRAM_ALLOWED_USERS`; остальным бот сообщает их Telegram ID.
- Вопрос → карточка с настройками и оценкой стоимости → «Начать» → одно обновляемое сообщение с прогрессом и кнопкой «Остановить».
- Результат: короткий итог (до ~700 символов по границе абзаца) и кнопки: подробнее, голосование, полный отчёт, итог, только решение, «Уточнить», «Повторить».

- Длина вопроса не ограничена: части длинного сообщения, которые Telegram разрезал, склеиваются. В карточке настроек — «🔎 Факты» и «📝 Компактно»; в оценке стоимости — остаток на балансе.
- Команды: /settings, /budget, /evaluate, /archive, /stats, /logs, /stop, /cancel, /clear, /ask (в группах). Файлы и голосовые принимаются как вложения или вопрос. Одно заседание на чат одновременно; события одного чата обрабатываются по порядку.
- Демо-режим (без затрат) можно включить в настройках чата.

14. Статистика

Считается по всем сохранённым стенограммам (`stats.py`):

- число заседаний; общие расходы; расходы и число заседаний за текущий месяц; средняя стоимость и длительность; число заседаний с файлами и уточнений; распределение по режимам; помесячно за 12 месяцев;
- по каждой модели: участие, число предложений, побед (вариант модели выбран председателем), доля побед, средняя оценка критики, средний балл Борда, число сбоев, расходы всего и на заседание.

Модели сортируются по доле побед. Важно: статистика описательная; небольшое число заседаний, разные составы и вопросы не позволяют делать строгих выводов о качестве моделей.

15. Безопасность и развёртывание

- **Ключи** (`OPENROUTER_API_KEY`, токен бота, пароль веба) хранятся в файле `.env` на сервере и не попадают в код и архив.
- **Веб-доступ:** вход по логину и паролю (HTTP Basic, сравнение за постоянное время), блокировка IP на 15 минут после 10 неудачных попыток. Без пароля интерфейс должен работать только на localhost.
- **HTTPS:** обратный прокси Caddy с автоматическим сертификатом Let's Encrypt (для сервера без домена — домен вида `<ip>.sslip.io`).
- **Файлы:** проверка имён и расширений, ограничение размеров, безопасные имена при сохранении; идентификаторы заседаний проверяются по шаблону (защита от выхода за пределы папки).
- **Развёртывание:** Docker и docker compose (профили: бот, веб, HTTPS); установщик `install.sh` задаёт все вопросы с пошаговыми инструкциями и создаёт команду `ai-council` (status, logs, restart, update, ask, archive, reports, stats, config, password, access, backup и др.).
- **Данные** пользователей (вопросы, файлы) передаются в OpenRouter и далее провайдерам моделей — это стоит учитывать для конфиденциальной информации.

16. Известные ограничения и вопросы для анализа

Ниже — места, где логика опирается на допущения. Их полезно оценить при анализе.

Методология совета

1. Анонимность неполная

Модели могут узнать «свой» или чужой стиль и формат. Метки скрывают имя, но не манеру письма. Возможен эффект предпочтения вариантов, похожих на собственный.

2. Председатель — судья (смягчено)

У председателя нет своего варианта, и он следует голосованию: другой победитель — только по причине fact / risk / process, которая выделяется в отчёте. Он по-прежнему голосует и пишет итоговый текст, поэтому его вкус влияет на формулировки.

3. Критика относится к версиям до доработки (снято)

Оценки критики больше не участвуют в подсчёте; председатель видит, что изменено после критики и что автор не принял.

4. Равный вес критериев и голосов

Все критерии и все бюллетени весят одинаково; уверенность модели (`confidence`) в подсчёте не используется. Число голосующих за вариант может различаться (выбывшие участники); это видно по покрытию пар.

5. Конформизм при доработке

Модели видят критику и чужие варианты и могут сходиться к одному решению. Это повышает согласованность, но может снижать разнообразие. Инструкции требуют «не менять в угоду критикам», но гарантий нет.

6. Уточнённая формулировка задаётся одной моделью

Председатель на этапе 0 переформулирует вопрос и выбирает критерии; ошибка на этом шаге влияет на всё заседание. Пользователь может задать критерии сам.

Технические аспекты

7. Бюджет может быть немного превышен

Проверка лимита выполняется перед каждым запросом, но запросы одного этапа уходят параллельно — превышение возможно на стоимость уже отправленных запросов.

8. Голосование с ограниченными вложениями

На этапе голосования модели получают документы, только если вместе они не больше 20 000 символов; картинки не передаются.

9. Контекст уточнений ограничен

В уточнение передаются только итоговые решения (до 4000 символов) последних 4 заседаний цепочки, без хода обсуждения.

10. Воспроизводимость

Результаты не детерминированы (температура 0,7, разные версии моделей у провайдера). Повтор заседания — новое независимое обсуждение. Фактическая модель, ответившая на каждый запрос, записывается в стенограмму.

11. Оценка стоимости приблизительная

Учитывает длину вопроса и вариантов, то, что каждая модель читает все варианты, и длины ответов из прошлых заседаний (верхняя граница ×1,6, без истории ×2,5). Кэширование может сделать фактическую цену ниже оценки.

14. Компактные варианты теряют детали

В компактном режиме полный текст пишет только председатель; детали, не попавшие в сжатые варианты, в итог не попадут.

12. Фактическая проверка (опция)

Проверка фактов через поиск включается отдельно и охватывает только лидеров голосования; поиск — дополнительный сигнал, а не гарантия. Согласие нескольких моделей само по себе фактической верности не гарантирует.

13. Пометка бюллетеней — не приговор

Пометка не отличает стратегическое голосование от честного несогласия, поэтому голоса не отбрасываются, а показывается устойчивость лидера.

Возможные направления развития

Уже сделано: председатель без своего варианта и следующий голосованию; обязательные требования; метод Шульце; честная ничья за первое место; решающие голоса и покрытие пар; случайный порядок вариантов для каждого судьи; мера согласия; проверка бюллетеней; проверка фактов (со статусом «из документов пользователя»); небольшие документы на голосовании; компактные варианты и кэширование.

- Учёт уверенности моделей и весов критериев в подсчёте.
- Шульце по разнице голосов (margins) — как эксперимент для сравнения.

- Проверка фактов и для варианта, выбранного председателем не из лидеров.

Приложение. Карта исходного кода

Файл	Содержимое
`council/session.py`	Класс `Council`: этапы 0–6, `_ask` (запрос + проверка + повторы), `_parallel`, бюджет, кворум, события, `SessionResult`.
`council/prompts.py`	Системная инструкция и шаблоны запросов всех этапов, блок истории для уточнений, описание картинок, просьба исправить JSON.
`council/schemas.py`	Схемы ответов моделей.
`council/voting.py`	Извлечение JSON, метки, нормализация критики и ранжирования, подсчёт Борда.
`council/client.py`	Клиент OpenRouter: поток, повторы, пустые ответы, учёт стоимости, каталог моделей.
`council/config.py`	Настройки, проверка, переопределения, чтение `.env`.
`council/estimate.py`	План вызовов, оценка стоимости, проверка моделей, определение «зрения».
`council/attachments.py`	Чтение файлов, извлечение текста, уменьшение картинок, лимиты, объединение.
`council/transcribe.py`	Декодирование аудио и расшифровка.
`council/archive.py`, `report.py`	Архив, сохранение, поиск, отчёты, цепочки уточнений, исходные настройки.
`council/stats.py`	Статистика.
`council/reports/`	`view.py` (представление), `html.py`/`pdf.py`, `docx.py`, `md.py`, `brand.py`.
`council/cli.py`	Командная строка.
`council/web/`	`app.py` (API, SSE), `auth.py` (пароль), `static/` (страница).
`council/telegram/`	`bot.py` (логика бота), `api.py` (Bot API), `format.py`.
`council/mock.py`	Демо-клиент без затрат (для тестов и пробы).
`config.yaml`, `install.sh`, `Dockerfile`, `docker-compose.yml`	Настройки, установщик, развёртывание.
`tests/`	Автотесты (154): оркестратор, клиент, оценка, вложения, отчёты, веб, бот, новые функции.